Никита Баринов

ML-инженер | Генеративный ИИ, LLM и мультимодальные системы

barinov.na@phystech.edu · +7 (905) 133-08-50
GitHub · LinkedIn · Telegram

Выпускник магистратуры МФТИ (2026). Опыт в VK, Т-Банке, Sber AI и Яндексе. Разрабатываю ML-системы полного цикла: от экспериментов и обучения до оптимизации инференса, внедрения и проверки результатов в A/B-тестах.

ОПЫТ РАБОТЫ

ML-инженер | AI VK — Окт 2025 - Настоящее время

Генеративный ИИ для рекламы — Июль 2026 - Настоящее время

Go · Python · PyTorch · vLLM-Omni · Temporal · PostgreSQL · Kafka · S3 · Docker · Prometheus

- Создал и запустил пайплайн превращения статичных баннеров в видеорекламу: от автоматического написания сценария до генерации изображений и видео.
- Заменил шаблонную генерацию: число кликов выросло на 33%, конверсий - на 19%, CPC снизился на 21%, CPA - на 11%. Рекламные расходы при этом выросли всего на 5%.
- Оптимизировал инференс MiniMax H3 (TI2V) на vLLM-Omni: ускорил генерацию примерно в 4 раза на бенчмарках за счёт настройки attention-бэкенда и числа шагов денойзинга. Тензорный параллелизм позволил снизить расход памяти на одну GPU на 28%.
- Реализовал асинхронные процессы генерации в Temporal, связав API моделей, хранилище результатов и аналитику.

LLM и мультимодальный ИИ для VK Видео — Октябрь 2025 - Июнь 2026

PyTorch · vLLM · Kubernetes · Triton Inference Server · TensorRT · ONNX · Docker · DVC (S3) · YTsaurus

- Дообучал эмбеддинг-модели на основе LLM для поиска; улучшил результаты на внутренних тестах релевантности.
- Разработал воспроизводимый процесс экспериментов и провёл более 100 обучений, расширив охват и разнообразие данных для оценки релевантности.
- Разработал мультимодальные модели контента и повысил полноту (recall) на 14% при фиксированной точности (precision) 0.90.
- Дистиллировал OpenAI o3 в компактную модель релевантности. На внутренних оценках достиг consistency recall 0.93 и precision 0.95.
- Развернул модели в продакшне на Triton Inference Server; оптимизировал инференс с помощью TensorRT и ONNX.

ML-инженер | Tinkoff AI Center — Сен 2024 - Сен 2025

Python · SQL · Transformers · Sequential Models · Polars · Airflow · Docker · CatBoost

- Вёл разработку рекомендательной модели на основе Transformer: от исследований и обучения до внедрения в генерацию кандидатов. В A/B-тесте время пользователей в сервисе выросло на 7%.
- Поддерживал рабочие ML-пайплайны: пакетный инференс, переобучение, мониторинг и проверку качества данных.
- Автоматизировал обучение и развёртывание моделей с помощью Airflow и Docker.

Data Scientist, стажёр | Sber AI — Фев 2024 - Авг 2024

Python · PyTorch · Diffusion models · Grounded-SAM · LLaVA · Computer Vision · WebDataset · Accelerate · Distributed

- Создал пайплайн генерации датасета для редактирования изображений по текстовым инструкциям на основе Stable Diffusion, Grounded-SAM, LLaMA и LLaVA-NeXT.
- Сгенерировал миллионы обучающих примеров; ускорил загрузку данных с помощью WebDataset.

ML-инженер, стажёр | Yandex Music — Июн 2023 - Ноя 2023

Python · SQL/YQL · RecSys · Embeddings · CatBoost · Feature Engineering · Pandas · NumPy

- Внедрил Transformer-эмбеддинги треков в рабочий пайплайн предсказания следующего трека в Яндекс Музыке.
- Разработал пайплайн расчёта признаков на Python и YQL для больших объёмов данных о действиях пользователей.

НАВЫКИ

LLM и RAG: LLM, LangChain, RAG, Agentic RAG, GraphRAG, Qdrant, Vector Search, LLM Fine-Tuning, Knowledge Distillation, Information Retrieval

Глубокое обучение: PyTorch, Transformers, Multimodal AI, Generative AI, Image Generation, Video Synthesis, Diffusion Models, Audio ML, Whisper

ML в продакшене: Python, Go, vLLM, vLLM-Omni, Inference Optimization, Model Quantization, GPU Computing, Tensor Parallelism, MLflow, Triton Inference Server, TensorRT, ONNX

Рекомендательные системы: Sequential Models, Transformers, Vector Search, CatBoost

Компьютерное зрение: Stable Diffusion, Grounded-SAM, LLaVA, Object Detection

Инфраструктура и MLOps: Docker, Kubernetes, FastAPI, Airflow, Temporal, Kafka, S3, Prometheus, YTsaurus, PostgreSQL, DVC[S3], Distributed Training, WebDataset

ОБРАЗОВАНИЕ

МФТИ - магистратура, прикладная математика и информатика | Сен 2024 - Июн 2026

МФТИ - бакалавриат, прикладная математика и информатика | Сен 2020 - Июн 2024

Кафедра анализа данных МФТИ и ШАД Яндекса | Сен 2022 - Май 2024

ИССЛЕДОВАТЕЛЬСКИЕ ПРОЕКТЫ

Garage - генеративная аугментация данных 2024

Разработал Python-фреймворк для автоматической замены объектов на изображениях: GroundingDINO для поиска объектов, PowerPaint для генерации замены. Поддерживает массовую аугментацию датасетов и интерфейс на Gradio.

ЛИЧНЫЕ ПРОЕКТЫ

Audio RAG Апр 2026 - Настоящее время

Создал RAG-систему для аудиоконтента с развёртыванием на Triton Inference Server. Реализовал распознавание речи с Whisper и временными метками слов. Интегрировал BGE-M3 мультиязычные эмбеддинги с Qdrant vector DB.

Сравнение RAG архитектур Сен 2025 - Настоящее время

Реализовал классический RAG, GraphRAG и агентный RAG. Создал систему оценки ответов на вопросы, требующие нескольких шагов поиска. Использовал локальный LLM + embedding сервер.

Audio Question Answering Янв 2026 - Фев 2026

Реализовал AudioLLM, объединив энкодер Whisper и языковую модель. Разработал пайплайн обучения с адаптером между аудиоэнкодером и LLM. Сгенерировал QA датасет из LibriSpeech.

AI Генератор мемов из новостей Июн 2025 - Июл 2025

Создал автоматический парсер новостей для российских источников (Lenta.ru, RIA.ru). Реализовал классификацию тем с помощью LLaMA 3.1 и few-shot обучения. Создал RAG пайплайн для генерации шуток с учетом контекста.

ShopSpy - Трекер цен Мар 2026 - Настоящее время

Создал браузерное расширение для отслеживания цен на Wildberries и Ozon. Реализовал детектор фейковых скидок на основе анализа истории цен. Интегрировал AI-суммаризацию отзывов с помощью Gemini API.

ДОПОЛНИТЕЛЬНОЕ ОБРАЗОВАНИЕ

Курс по обработке речи | Школа анализа данных Яндекса | Сен 2025 - Янв 2026

Интенсив по ИИ-агентам | Яндекс | Апр 2026